통계자료캡스톤디자인

알고리즘 B팀 - 정연우 정희진

1. 프로젝트 개요

- 팀 별로 최적 파라미터 조합 찾기
- 팀 별로 모델 검증 방법 고안

비관적 포트폴리오에 기반한 모델 검증 방법 고안하기

=> 모델의 예측 분포에서 **하방 tail 리스크를 최소화**하도록 학습하자**!**

2. Hyper parameter Tuning

분기_하이퍼파라미터 별

model_dimension = 16, 64

model_dimension 16 : 22개 (년도_분기) * 16개 (하이퍼파라미터) = 352개 행 결과

model_dimension 64 : 22개 (년도_분기) * 16개 (하이퍼파라미터) = 352개 행 결과

```
runs.summary["Results Table"]
```

Filter

	분기_파라미터조합	Best Train Loss	Best Valid Loss	MAE	RMSE	MAPE	SMAPE	PICP
1	2020_Q1_lr0.001_demb8_dmodel64_drop0.5_nheads4	28.786	24.792	49.769	2163.188	1474.635	130.089	0.8113
2	2020_Q2_lr0.001_demb8_dmodel64_drop0.5_nheads4	24.714	25.816	51.842	2183.03	897.648	139.821	0.8131
3	2020_Q3_lr0.001_demb8_dmodel64_drop0.5_nheads4	22.753	16.39	32.991	1707.659	971.415	136.335	0.8003
4	2020_Q4_lr0.001_demb8_dmodel64_drop0.5_nheads4	23.719	11.403	23.029	1388.608	410.203	152.009	0.6051
5	2021_Q1_lr0.001_demb8_dmodel64_drop0.5_nheads4	24.234	11.229	22.718	1373.692	526.694	155.38	0.7656
6	2021_Q2_lr0.001_demb8_dmodel64_drop0.5_nheads4	23.095	11.199	22.641	1372.265	736.662	132.319	0.8311
7	2021_Q3_lr0.001_demb8_dmodel64_drop0.5_nheads4	22.716	5.982	12.256	966.645	426.086	148.668	0.8052
8	2021_Q4_lr0.001_demb8_dmodel64_drop0.5_nheads4	20.446	19.639	39.585	4082.382	44658.191	138.714	0.7558
9	2022_Q1_lr0.001_demb8_dmodel64_drop0.5_nheads4	19.881	37.826	75.914	5720.928	270038.477	121.349	0.6294
10	2022_Q2_lr0.001_demb8_dmodel64_drop0.5_nheads4	18.313	37.748	75.742	5716.626	204771.985	109.118	0.844
11	2022_Q3_lr0.001_demb8_dmodel64_drop0.5_nheads4	17.254	23.747	47.855	4151.166	122129.761	131.253	0.7811
12	2022_Q4_lr0.001_demb8_dmodel64_drop0.5_nheads4	19.628	66.017	132.345	11592.982	861.026	125.386	0.7696
13	2023_Q1_lr0.001_demb8_dmodel64_drop0.5_nheads4	21.86	120.169	240.668	16167.335	436.221	144.916	0.7526

1 - 14 of 1058

Export as CSV Columns... Reset table

3. Evaluation Metrics

MAE, RMSE: 예측 정확도

SMAPE, MAPE: 예측 안정성

PICP, Quantile risk : 불확실성 관리

Expected Shortfall, Tail Coverage : 하방 리스크

=> 예측이 불확실할수록 리스크가 커진다!!!!!

Validation Strategy 1 : 가중치 Metric

- 현재 사용한 metric인 MAE, RMSE, SMAPE, MAPE, PICP에 가중치를 부여한 새로운 custom metric을 만들자.

- 가중치의 기준을 어떻게 설정할 것인가?

: 리스크를 최소화하자는 목적을 더 강화하는 PICP에 높은 가중치를 두는 Metric

Validation Strategy 1 : 가중치 Metric

1. 각 지표를 “좋을수록 큰 값”으로 변환한 뒤 순위를 매기고, 기수법으로 하나의 스칼라로 인코딩한다.
- PICP: PICP 점수의 내림차순 순위
- rMAE,rRMSE,rsMAPE: 각 지표를 min–max로 정규화 후 “좋음” 점수 e=1−x^의 내림차순 순위
2. 표본 개수 N에 대해 B=N+1
3. $$\text{Score} = r_{\text{PICP}}\, B^3 + r_{\text{MAE}}\, B^2 + r_{\text{RMSE}}\, B^1 + r_{\text{sMAPE}}\, B^0$$

어떤 하위 항들의 합도 상위 항을 절대 넘지 못해, PICP가 자동으로 가장 큰 가중치를 가짐.

Validation Strategy 1 : 가중치 Metric

quarter_key	분기_파라미터조합	score	score_norm	MAE	rMSE	sMAPE	PICP
2020_Q1	2020_Q1_lr0.001_demb8_dmodel64_drop0.5_nheads1	13.385935	0.892396	49.796658	2163.186523	133.347118	0.800435
2020_Q2	2020_Q2_lr0.0005_demb8_dmodel64_drop0.1_nheads1	13.351289	0.890086	51.913937	2183.034668	129.906619	0.797780
2020_Q3	2020_Q3_lr0.001_demb8_dmodel64_drop0.5_nheads4	13.674610	0.911641	32.990780	1707.658569	136.334610	0.800298
2020_Q4	2020_Q4_lr0.0005_demb8_dmodel64_drop0.5_nheads1	13.974338	0.931623	22.912479	1388.637085	128.892016	0.801477
2021_Q1	2021_Q1_lr0.001_demb8_dmodel64_drop0.5_nheads1	14.020876	0.934725	22.595882	1373.603882	126.342642	0.801637
2021_Q2	2021_Q2_lr0.001_demb8_dmodel64_drop0.1_nheads1	13.982008	0.932134	22.651171	1372.267334	121.605515	0.794578
2021_Q3	2021_Q3_lr0.0005_demb4_dmodel64_drop0.1_nheads4	14.194050	0.946270	12.072998	966.649658	121.848178	0.805742
2021_Q4	2021_Q4_lr0.001_demb8_dmodel64_drop0.1_nheads1	13.462679	0.897512	39.369808	4082.371826	117.866182	0.795501
2022_Q1	2022_Q1_lr0.001_demb8_dmodel64_drop0.1_nheads4	12.658305	0.843887	75.854706	5720.929688	116.910207	0.795181
2022_Q2	2022_Q2_lr0.0005_demb4_dmodel16_drop0.1_nheads4	12.587910	0.839194	76.325333	5716.644043	126.585317	0.798496
2022_Q3	2022_Q3_lr0.0005_demb8_dmodel16_drop0.5_nheads1	13.279911	0.885327	48.054810	4151.179688	119.859803	0.804333
2022_Q4	2022_Q4_lr0.0005_demb8_dmodel64_drop0.1_nheads1	11.019482	0.734632	132.316422	11592.979492	116.519916	0.795875
2023_Q1	2023_Q1_lr0.001_demb8_dmodel64_drop0.1_nheads1	8.437920	0.562528	240.907532	16167.334961	130.172801	0.796898
2023_Q2	2023_Q2_lr0.001_demb8_dmodel64_drop0.5_nheads4	8.443090	0.562873	232.145660	16135.431641	136.875570	0.796027
2023_Q3	2023_Q3_lr0.0005_demb8_dmodel64_drop0.5_nheads1	11.126527	0.741768	112.081703	11356.690430	128.090310	0.794075
2023_Q4	2023_Q4_lr0.001_demb8_dmodel64_drop0.5_nheads1	14.343477	0.956232	1.887456	15.259336	134.043121	0.803398
2024_Q1	2024_Q1_lr0.0005_demb4_dmodel64_drop0.1_nheads4	14.505509	0.967034	1.430616	9.891337	124.711967	0.803685
2024_Q2	2024_Q2_lr0.0005_demb4_dmodel64_drop0.5_nheads4	14.465712	0.964381	1.491951	12.374162	121.616173	0.806583
2024_Q3	2024_Q3_lr0.001_demb8_dmodel64_drop0.1_nheads4	14.503443	0.966896	9.713092	929.899170	116.073334	0.800582
2024_Q4	2024_Q4_lr0.0005_demb4_dmodel16_drop0.1_nheads4	13.970164	0.931344	26.862894	1631.653564	121.828508	0.802466
2025_Q1	2025_Q1_lr0.0005_demb8_dmodel16_drop0.1_nheads4	13.567188	0.904479	35.185284	1877.415771	139.220643	0.799719
2025_Q2	2025_Q2_lr0.001_demb8_dmodel64_drop0.1_nheads4	14.052045	0.936803	26.385336	1626.262939	117.033958	0.797207

Validation Strategy 2 : Asymmetric Loss

비대칭 손실 기반 검증

"과대예측과 과소예측의 비용이 다르다"

- 과소예측 시 => 기회 손실 (투자를 덜 한다)
- **과대예측 시 => 손실 위험 (과투자)** + 가중치 부여

=> 검증 시 비대칭 가중치를 부여하는 Metric을 사용해보자

```
def asymmetric_loss(y_true, y_pred, alpha=2.0):
    # 과대예측(positive error)에 더 큰 패널티
    error = y_pred - y_true
    loss = np.where(error > 0, alpha * error**2, error**2)
    return loss.mean()
```

Validation Strategy 3 : CVaR

goal 평균적인 상황에서의 최적화를 넘어, 극단적 손실이라는 개념을 직접 관리하자

CVaR

- 손실이 VaR를 초과하는 최악의 경우, 평균적으로 어느 정도의 손실이 발생하는가?
- 수익률 하위 α%에 해당하는 최악 상황에서의 평균 손실 값

Quantile Loss는 구조상 이미 분위수 전체에 대한 평균 성능을 보여주지만 tail 구간의 리스크 제어를 보장하지 않는다.

따라서 우리의 목표를 더 구체화할 수 있는 validation loss의 보완 지표가 필요하다.

⇒ CVaR metric을 사용하여 모델이 실제로 극단 손실을 얼마나 잘 완화했는지 검증한다.

Validation Strategy 4 : Stability

$$\text{Stability} = 1 - \frac{\text{Var}(\text{CVaR}_{\text{quarters}})}{\text{Mean}(\text{CVaR}_{\text{quarters}})}$$

- 모델의 CVaR이 시점별로 얼마나 일관되게 유지되는지를 측정
- 값이 1에 가까울수록 tail-risk가 일정하게 관리되고 있음을 의미
- 반값이 낮을수록 모델이 특정 시점에 따라 위험이 크게 달라지는 불안정한 구조임을 시사

⇒ 분기별로 tail risk를 안정적으로 유지하는지를 수치화한 리스크 일관성 척도

7. Validation Results

Validation Strategy 1의 가중치 metric 실험 중입니다.

질문 & 논의점

1. 검증 방법이라는 것이 최적 파라미터 조합을 찾는 방법을 의미하는지?
2. 보통 검증 방법에 평가지표를 (만들어서) 사용하는 것 말고 어떤 방법 있는지?
3. 새로 만든 매트릭이 신뢰할 수 있음을 어떻게 증명할 것인가?
4. 현재 우리의 목표는 과대예측을 줄이는 것이지만 SMAPE는 대칭 오차를 나타낸다. validation strategy 2인 Asymmetric Loss와 상충되는 개념이 아닐까?
   우리의 목표 가정 하에서는 SMAPE는 사용하면 안되려나?
5.